一、浮点加减的步骤

1.1 引例

浮点加减法运算

【引例】

$$0.132\times10^5+0.408\times10^2=0.132\times10^5+0.000408\times10^5$$

对阶

$$=(0.132+0.000408)\times10^5$$

尾数运算

$$=0.132408\times10^5$$

结果规格化

- 在尾数右规时，尾数末位的几位会因超出计算机字长而被丢弃，从而产生误差。此时，计算机可以按选定的方式进行舍入操作。
- 在尾数规格化和尾数舍入时，可能会对结果的阶码执行加、减运算。因此，必须考虑结果的阶码出现溢出的问题。
  - 由于浮点数中阶码的位数决定了浮点数的表示范围，因此，对于浮点运算，当阶码出现溢出时，表示运算结果出现溢出。

注:

- 注意到，首先应保证阶码对齐，然后就可转化成定点小数的加减法
- 在对结果规格化时，涉及阶码的加减，因此阶码可能溢出

1.2 具体步骤

*例1

【例1】 设$x=2^{-101}\times(-0.101011)$，$y=2^{-010}\times0.001110$，$x$和$y$的阶码和尾数都用双符号补码表示，阶码为3位、尾数为6位（均不含符号位），请按照浮点数加减法运算步骤计算$x+y$。

1. 对阶

解析：$E_x=-101$　　$M_x=-0.101011$　　$E_y=-010$　　$M_y=0.001110$

$[E_x]_{补}=11,011$　　$[M_x]_{补}=11.010101$　　$[E_y]_{补}=11,110$　　$[M_y]_{补}=00.001110$

小阶向大阶看齐　　已对阶

$$0.132\times10^5+0.408\times10^2=0.132\times10^5+0.000408\times10^5$$

尾数右移，舍弃尾数的低位

只有很小的精度缺失



若大阶向小阶看齐，会怎样?

尾数左移，丢失尾数的高位

造成严重的数值错误

不理解的同学，请复习
3-1-2 算术移位

注：对阶时，应当小阶做调整，因为算数右移只会丢失精度，而算数左移可能导致数值错误

对阶原则

解析：$E_x=-101$　　$M_x=-0.101011$　　$E_y=-010$　　$M_y=0.001110$

$[E_x]_{补}=11,011$　　$[M_x]_{补}=11.010101$　　$[E_y]_{补}=11,110$　　$[M_y]_{补}=00.001110$

对阶原则： 小阶向大阶看齐，尾数右移相应位数（两个阶的差的绝对值）

$$[E_x]_{补}-[E_y]_{补}=[E_x]_{补}+[-E_y]_{补}=11,011+00,010=11,101=[E_x-E_y]_{补}$$

$E_x-E_y=-3$　这表明：x的阶码比y的阶码小3

因此，x的阶码应向y的阶码看齐（即相同）；相应地，需要将x的尾数向右移动3位

对阶后：$[E_x]_{补}=[E_y]_{补}=11,110$　　$[M_x]_{补}=11.010101$ ⇢（算术右移3位）$11.111010(101)$

移出位暂时保留，称为保留附加位。保留附加位参与中间运算以提高运算精度：尾数运算结束，结果规格化后再进行舍入。

2. 尾数运算

解析：$E_x=-101$　　$M_x=-0.101011$　　$E_y=-010$　　$M_y=0.001110$

$[E_x]_{补}=11,011$　　$[M_x]_{补}=11.010101$　　$[E_y]_{补}=11,110$　　$[M_y]_{补}=00.001110$

对阶后：$[E_x]_{补}=[E_y]_{补}=11,110$　　$[M_x]_{补}=11.111010(101)$

尾数运算后：$[M_x+M_y]_{补}=00.001000(101)$ 这表示的是规格化的尾数吗？



最高数值位不是有效值
因此不是规格化的尾数

3. 规格化

解析：$E_x=-101$　　$M_x=-0.101011$　　$E_y=-010$　　$M_y=0.001110$

$[E_x]_{补}=11,011$　　$[M_x]_{补}=11.010101$　　$[E_y]_{补}=11,110$　　$[M_y]_{补}=00.001110$

对阶后：$[E_x]_{补}=[E_y]_{补}=11,110$　　$[M_x]_{补}=11.111010(101)$

尾数运算后：$[M_x+M_y]_{补}=00.001000(101)$　最高数值位不是有效值 因此不是规格化的尾数

左 规

- 尾数运算结果为$11.1bb\ldots b$或$00.0bb\ldots b$：
  - ○ 尾数每左移1位，阶码减1，直到尾数成为规格化数为止。
  - ○ 还需要判断阶码是否下溢。若发生下溢（符号位为10），可认为结果为0。

右 规

- 尾数运算结果为$10.bb\ldots b$或$01.bb\ldots b$，即尾数运算结果溢出：
  - ○ 尾数只需要右移1位，阶码加1。
  - ○ 还需要判断阶码是否上溢。若发生上溢（符号位为01），可认为结果为∞。

不理解“上溢”和“下溢”概念的同学，请复习2-4-1 浮点数的表示形式和表示范围

注：关于浮点数的溢出现象，参考[[2.8 浮点数的表示形式以及表示范围]]

解析：$E_x=-101$　　$M_x=-0.101011$　　$E_y=-010$　　$M_y=0.001110$

$[E_x]_{补}=11,011$　　$[M_x]_{补}=11.010101$　　$[E_y]_{补}=11,110$　　$[M_y]_{补}=00.001110$

对阶后：$[E_x]_{补}=[E_y]_{补}=11,110$　　$[M_x]_{补}=11.111010(101)$

尾数运算后：$[M_x+M_y]_{补}=00.001000(101)$　最高数值位不是有效值 因此不是规格化的尾数

算术左移2位（左规）

$00.100010(1)$

有2位保留附加位直接移入了数值位。因此，采用保留附加位可以提高运算精度。

相应的，将阶码减2：

$$[E]_{补}=[E_y]_{补}+[-2]_{补}$$
$$=11,110+11,110$$
$$=11,100$$

当阶码的符号位为01（上溢）和10（下溢）时，表示溢出。因此，本例未溢出。

4. 舍入

解析： $E_x = -101$　　$M_x = -0.101011$　　$E_y = -010$　　$M_y = 0.001110$

$[E_x]_{补} = 11,011$　　$[M_x]_{补} = 11.010101$　　$[E_y]_{补} = 11,110$　　$[M_y]_{补} = 00.001110$

对阶后： $[E_x]_{补} = [E_y]_{补} = 11,110$　　$[M_x]_{补} = 11.111010(101)$

尾数运算后： $[M_x + M_y]_{补} = 00.001000(101)$

结果规格化后： $[M_x + M_y]_{补} = 00.100010(1)$　　$[E]_{补} = 11,100$

对阶（算术右移）产生的

00.100010　（截断法）

00.100011　（末位恒置1法）

00.100011　（0舍1入法）

在进行对阶时会用到算术右移，而进行结果规格化时，可能会用到算术右移。这会导致尾数末位的几位因超出机器字长而被丢掉，从而产生误差。此时，机器可按选定方式进行舍入处理：

注：0舍1入法，可能使结果再次变为非规格化数