2.8 浮点数的表示形式以及表示范围

考纲定位：计算机组成原理 · 第 2 章 数据的表示和运算（2.8） | 重要度 ★★★★★ | 常见考法：选择题（浮点格式、阶码/尾数作用、表示范围、上溢下溢）

一句话核心：浮点数 = 阶码 + 尾数；阶码决定表示范围，尾数决定表示精度

一、定点数的表示总结

定点数表示

	机器字长为$n+1$位（1个符号位，n个数值位）						
	定点小数表示范围			定点整数表示范围			
	原 码	反 码	补 码	原 码	反 码	补 码	移 码
最大正数	$0.111\cdots11$ $(1-2^{-n})$	$0.111\cdots11$ $(1-2^{-n})$	$0.111\cdots11$ $(1-2^{-n})$	$0,111\cdots11$ (2^n-1)	$0,111\cdots11$ (2^n-1)	$0,111\cdots11$ (2^n-1)	$1,111\cdots11$ (2^n-1)
最小正数	$0.000\cdots01$ (2^{-n})	$0.000\cdots01$ (2^{-n})	$0.000\cdots01$ (2^{-n})	$0,000\cdots01$ (1)	$0,000\cdots01$ (1)	$0,000\cdots01$ (1)	$1,000\cdots01$ (1)
0	$0.000\cdots00$ $1.000\cdots00$	$0.000\cdots00$ $1.111\cdots11$	$0.000\cdots00$	$0,000\cdots00$ $1,000\cdots00$	$0,000\cdots00$ $1,111\cdots11$	$0,000\cdots00$	$1,000\cdots00$
最大负数	$1.000\cdots01$ (-2^{-n})	$1.111\cdots10$ (-2^{-n})	$1.111\cdots11$ (-2^{-n})	$1,000\cdots01$ (-1)	$1,111\cdots10$ (-1)	$1,111\cdots11$ (-1)	$0,111\cdots11$ (-1)
最小负数	$1.111\cdots11$ $-(1-2^{-n})$	$1.000\cdots00$ $-(1-2^{-n})$	$1.000\cdots00$ (-1)	$1,111\cdots11$ $-(2^n-1)$	$1,000\cdots00$ $-(2^n-1)$	$1,000\cdots00$ (-2^n)	$0,000\cdots00$ (-2^n)

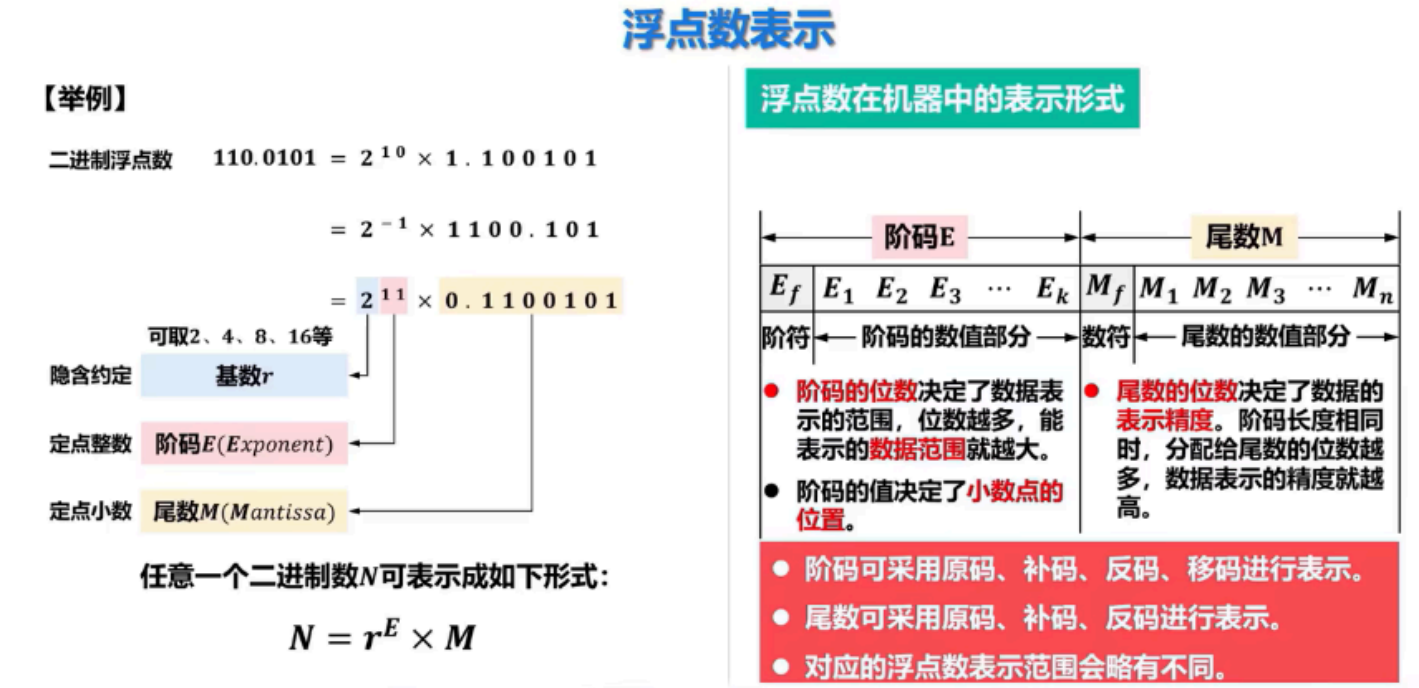
■ 定点数所能表示的数据范围与下列因素有关。

- ☐ 机器字长：字长越长，其表示的数据范围就越大。
- ☐ 所采用的机器码：补码和移码所能表示的数据范围，比原码和反码所能表示的数据范围要多一个最小负数。

定点数

- 小数点位置固定
- 定点整数：小数点在最低位后
- 定点小数：小数点在符号位后
- 范围小、精度固定；超出范围就溢出

二、浮点数的表示



一般形式

$$N = r^E \times M$$

- r：基数，常取 2、8、16
- E：阶码，带符号的定点整数
- M：尾数，带符号的定点小数
- 类似十进制的科学计数法

存储格式

阶码 E	尾数 M
阶符 + 阶码数值	尾符 + 尾数数值

提炼

- 阶码决定小数点移动多少位，即范围
- 尾数决定有效数字位数，即精度
- 基数越大，同样阶码能表示的范围越大，但精度可能下降

易错

- 阶码是整数，尾数是小数
- 阶码和尾数都带符号
- 基数不一定是 2；408 常考 2

三、浮点数的表示范围

浮点数在机器中的表示形式

$N = r^E \times M$ (r可取2、4、8、16等)

浮点数表示范围

	阶码E					尾数M				
	E_f	E_1	E_2	E_3	$\cdots$ E_k	M_f	M_1	M_2	M_3	$\cdots$ M_n
	阶符	阶码的数值部分				数符	尾数的数值部分			
正数N最大值	最大值					正数最大值				
正数N最小值（浮点数的最小精度）	最小值					正数最小值				
负数N最小值	最大值					负数最小值				
负数N最大值	最小值					负数最大值				
【举例】	3位阶码（原码表示）（1个阶符，2个数值位）					3位尾数（原码表示）（1个数符，2个数值位）				
正数N最大值 $2^{+3} \times (+0.75)$	最大值0,11，即+3					正数最大值0.11，即+0.75				
正数N最小值 $2^{-3} \times (+0.25)$	最小值1,11，即−3					正数最小值0.01，即+0.25				
负数N最小值 $2^{+3} \times (-0.75)$	最大值0,11，即+3					负数最小值1.11，即−0.75				
负数N最大值 $2^{-3} \times (-0.25)$	最小值1,11，即−3					负数最大值1.01，即−0.25				

四个边界

- 最大正数：阶码最大、尾数正最大
- 最小正数：阶码最小、尾数正最小
- 最大负数：阶码最小、尾数负最大（绝对值最小）
- 最小负数：阶码最大、尾数负最大（绝对值最大）

规律

- 阶码位数越多，范围越大
- 尾数位数越多，精度越高
- 正数范围与负数范围关于 0 不对称（补码尾数时更明显）

例：阶码 3 位（含 1 位阶符，数值 2 位）、尾数 3 位（含 1 位尾符，数值 2 位），基数 2

- 阶码范围：$-4 \sim 3$（补码/移码按题设）
- 尾数绝对值范围：$0.25 \sim 0.75$（原码规格化）
- 最大正数约 $0.75 \times 2^3 = 6$
- 最小正数约 0.25×2^{-4}

易错

- 不要把“阶码最大”直接当“数值最大”；还要看尾数符号
- 范围由阶码和尾数共同决定
- 不同基数、不同码制，范围公式不同；按题设算

四、浮点数的溢出现象

浮点数表示范围

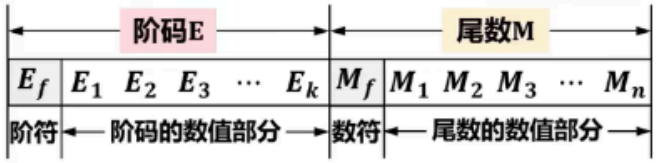
■ 尽管浮点数有效扩大了数据表示范围，但受机器字长限制，浮点数仍然存在溢出现象。

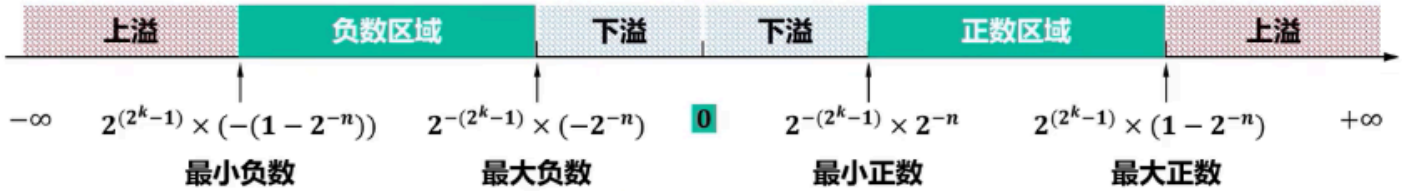
- □ 当浮点数的阶码大于最大阶码时，称为上溢，此时机器停止运算，浮点运算器件会显示溢出标志。
- □ 当浮点数的阶码小于最小阶码时，称为下溢，虽然此时数据不能被精确表示，但由于发生下溢时数据的绝对值很小，通常将尾数各位强置为0，按机器0处理，此时机器可以继续运行。

■ 当一个浮点数在正、负数区域中但并不在某个数轴刻度上时，也会出现精度溢出的问题，此时只能用近似数表示。

浮点数在机器中的表示形式

$N = r^E \times M$ (r可取2、4、8、16等)





上溢

- 阶码超过最大允许值
- 结果绝对值太大，无法表示
- 通常触发溢出异常

下溢

- 阶码小于最小允许值
- 结果绝对值太小，无法表示
- 通常按 0 处理或变为非规格化数

尾数溢出

- 尾数运算结果绝对值 ≥ 1
- 通过右规调整：尾数右移 1 位，阶码加 1
- 尾数溢出不一定是浮点溢出

阶码以及尾数的位数，会直接影响浮点数表示的精度以及范围，IEEE 关于阶码和尾数位数的规定如下

■ 一旦浮点数的位数确定后，合理分配阶码E和尾数M的位数，直接影响浮点数的表示范围和精度。

- □ 短实数（32位）：阶码E取8位（含1位阶符），尾数M取24位（含1位数符）。
- □ 长实数（64位）：阶码E取11位（含1位阶符），尾数M取53位（含1位数符）。
- □ 临时实数（80位）：阶码E取15位（含1位阶符），尾数M取65位（含1位数符）。

易错

- 上溢/下溢看阶码，不看尾数
- 尾数溢出可通过规格化解决
- 下溢不一定报错，可能按 0 处理

- 浮点数的 0 有特殊表示，不是“阶码最小、尾数最小”

知识关联：定点编码（2.3 定点数的原码）；规格化（2.9 浮点数的规格化）；IEEE 754（2.10 浮点数表示的IEEE 754标准）；浮点加减（3.18 浮点运算——加减法）