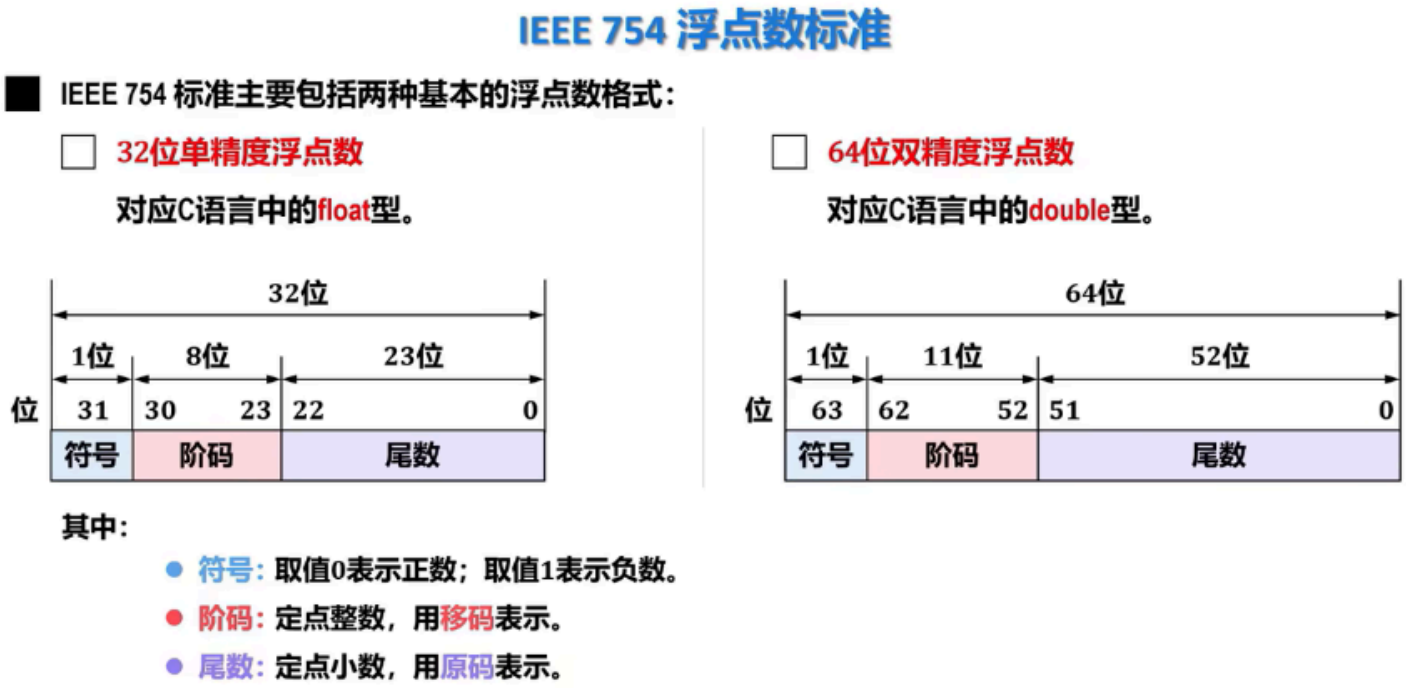
2.10 浮点数表示的IEEE 754标准

考纲定位：计算机组成原理 · 第 2 章 数据的表示和运算（2.10） | 重要度 ★★★★★ | 常见考法：大题（IEEE 754 编码、偏置阶码、隐藏位、特殊值、与真值互转）

一句话核心：IEEE 754 = 符号位 + 偏置阶码 + 隐藏位尾数；单精度 1+8+23，双精度 1+11+52

一、32位（单精度）、64位（双精度）浮点数标准



格式	总位数	符号 S	阶码 E	尾数 F	偏置
单精度	32	1	8	23	127
双精度	64	1	11	52	1023

真值公式

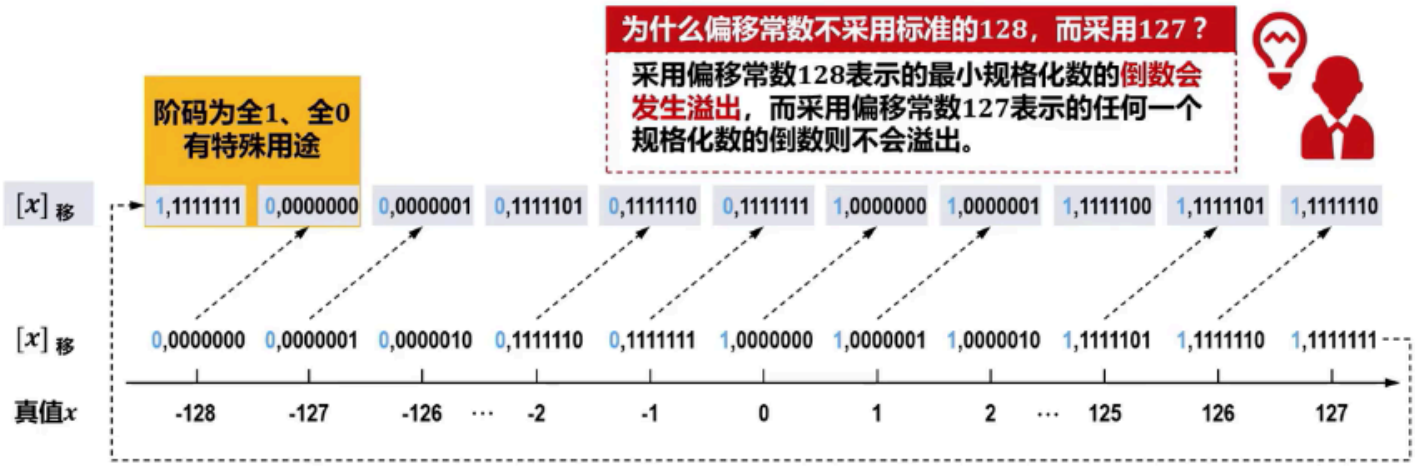
$$(-1)^S \times 1.F \times 2^{E-\text{bias}}$$

二、以单精度浮点数说明

2.1 关于阶码的规定

■ 在IEEE 754 浮点数标准中，32位单精度浮点数的8位阶码尽管采用移码表示，但采用偏移常数是$2^7-1=127$，而不是标准移码的$2^7=128$。

$$[x]_{移}=x+(2^7-1) \quad -2^7\le x<2^7$$



注

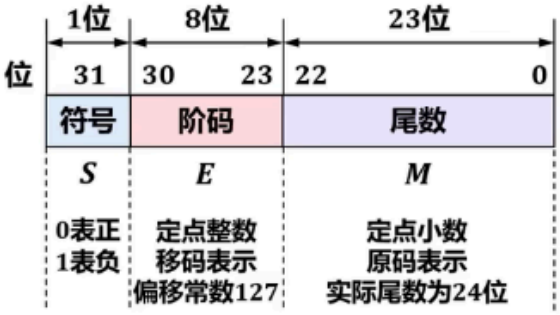
- 关于移码：2.6 定点数的移码、2.7A 原码、补码、反码、移码总结
- 关于偏移量为何采用 127：2.10A 浮点数移码偏移量的规定：IEEE754标准

规则

- 阶码用移码/偏置表示
- 单精度真阶码 $=E-127$
- 双精度真阶码 $=E-1023$
- 阶码全 0/全 1 保留给特殊值

2.2 具体编码规则

■ 下面以32位单精度浮点数为例介绍IEEE 754单精度浮点数标准。



- 符号：取值0表示正数；取值1表示负数。
- 阶码：定点整数，用移码表示，偏置常数$2^7-1=127$。
- 尾数：定点小数，用原码表示。符号位前移到最左侧。
  相邻左侧隐藏一个1，表示数值而不表示符号。
  尾数实际有24位，但不保存隐藏的那个1，只保存23位，节省的比特位可用于提高尾数的精度。
  完整的尾数形式为$1.M$

注

- 关于 $1.M$：只有规格化的浮点数，才默认隐藏了一个 1

- 关于 $0.M$：适用于非规格化浮点数

IEEE 754 单精度（32位）浮点数标准

	数值的分类	符号S	阶码E	尾数M	真值	
机器0	正零	0	0（全0）	0	$+0$	阶码E为全0
机器0	负零	1	0（全0）	0	-0	阶码E为全0
非规格化数	非规格化正数	0	0（全0）	$M \neq 0$	$(-1)^0 \times 2^{-126} \times 0.M$	阶码E为全0
非规格化数	非规格化负数	1	0（全0）	$M \neq 0$	$(-1)^1 \times 2^{-126} \times 0.M$	阶码E为全0
无穷大	正无穷大	0	255（全1）	0	$+\infty$	阶码E为全1
无穷大	负无穷大	1	255（全1）	0	$-\infty$	阶码E为全1
非数NaN	无定义数（非数）	0或1	255（全1）	$\neq 0$	$NaN(not\ a\ number)$	阶码E为全1
规格化数	规格化正数	0	$1 \leq E \leq 254$	M	$(-1)^0 \times 2^{E-127} \times 1.M$	阶码E非全0和全1
规格化数	规格化负数	1	$1 \leq E \leq 254$	M	$(-1)^1 \times 2^{E-127} \times 1.M$	阶码E非全0和全1

- 一般情况下，+0和−0是等效的。
- 非规格化数可用于处理阶码下溢，使得出现比最小规格化数还小的数时程序也能继续进行下去。
- 引入无穷大数可使计算过程出现异常的情况下程序能继续执行，并且可为程序提供错误检测功能。例如非0浮点数除0运算的结果就是无穷大，因此非0浮点数除0不会像整型数除0一样产生严重错误。
- 非数NaN则用于表示$\frac{0}{0}$、$\frac{\infty}{\infty}$、$0 \times \infty$、负数的平方根等。部分非数NaN运算结果可能会产生异常。

三类数

- 规格化数：阶码 1~254，尾数隐含 1，真值 $(-1)^S \times 1.F \times 2^{E-127}$
- 非规格化数：阶码 0，尾数隐含 0，真值 $(-1)^S \times 0.F \times 2^{1-127}$，用于渐进下溢
- 特殊值：阶码 255，尾数 0 表示 ±∞，尾数非 0 表示 NaN

特殊值表

阶码 E	尾数 F	含义
0	0	±0
0	非 0	非规格化数
1~254	任意	规格化数
255	0	±∞
255	非 0	NaN

易错

- 隐藏位 1 只对规格化数有效
- 非规格化数的隐藏位是 0
- 阶码字段不是补码，是偏置码
- 0 的阶码和尾数都是全 0

2.3 单精度、双精度浮点数编码对比

IEEE 754 浮点数标准

数值的分类	单精度（32位，对应C语言中的float）				双精度（64位，对应C语言中的double）			
	符号S	阶码E	尾数M	真值	符号S	阶码E	尾数M	真值
正零	0	0（全0）	0	$+0$	0	0（全0）	0	$+0$
负零	1	0（全0）	0	-0	1	0（全0）	0	-0
非规格化正数	0	0（全0）	$M \neq 0$	$(-1)^0 \times 2^{-126} \times 0.M$	0	0（全0）	$M \neq 0$	$(-1)^0 \times 2^{-1022} \times 0.M$
非规格化负数	1	0（全0）	$M \neq 0$	$(-1)^1 \times 2^{-126} \times 0.M$	1	0（全0）	$M \neq 0$	$(-1)^1 \times 2^{-1022} \times 0.M$
正无穷大	0	255（全1）	0	$+\infty$	0	2047（全1）	0	$+\infty$
负无穷大	1	255（全1）	0	$-\infty$	1	2047（全1）	0	$-\infty$
无定义数（非数）	0或1	255（全1）	$\neq 0$	$NaN(not\ a\ number)$	0或1	2047（全1）	$\neq 0$	$NaN(not\ a\ number)$
规格化正数	0	$1 \leq E \leq 254$	M	$(-1)^0 \times 2^{E-127} \times 1.M$	0	$1 \leq E \leq 2046$	M	$(-1)^0 \times 2^{E-1023} \times 1.M$
规格化负数	1	$1 \leq E \leq 254$	M	$(-1)^1 \times 2^{E-127} \times 1.M$	1	$1 \leq E \leq 2046$	M	$(-1)^1 \times 2^{E-1023} \times 1.M$

对比

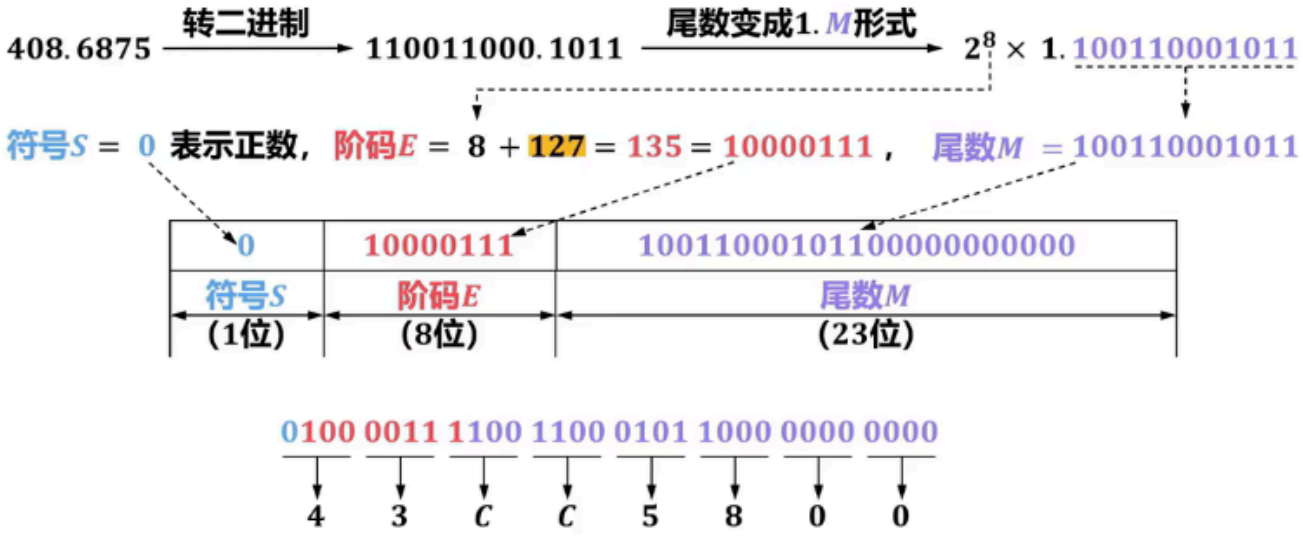
- 单精度：偏置 127，尾数 23 位，有效精度 24 位
- 双精度：偏置 1023，尾数 52 位，有效精度 53 位
- 双精度范围更大、精度更高，但占用空间更大

三、例题

例题1

【例题1】将十进制数408.6875转换成IEEE 754单精度浮点数的十六进制机器码。

解析：



注：对于转化过程，符号位是参与的，而且隐藏的 1 不需要手动添加；在底层阶码时，机器会自动识别，做出相应的解码操作

解题模板

1. 确定符号 S
2. 把绝对值转成二进制
3. 规格化成 $1.F \times 2^e$

4. 阶码字段 $E = e + \text{bias}$
5. 尾数字段取 F（去掉隐藏位 1）
6. 拼接 S/E/F

易错

- 阶码字段要加偏置，不是写真阶码
- 尾数字段不写隐藏位 1
- 规格化前先确定二进制小数点位置
- 负数符号位为 1，但数值部分按绝对值处理

四、关于计算误差

- **十进制小数转换成二进制小数时，可能出现无限循环小数，只能转换到符合精度要求的位数（即所谓的精度缺失）。**
- **IEEE 754浮点数格式位数有限（单精度32位、双精度64位），无法精确表示无限循环小数。**
  - **通常只能采用舍入的方式近似表示，因此会带来数据表示的误差。这种误差会在计算的过程中不断累积放大，可能导致严重后果。**

    【举例】采用双精度浮点数运算

    $$0.1 + 0.1 + 0.1 - 0.3 \neq 0$$

    $$0.7 - 0.2 \neq 0.5$$

    $$3.3 \div 1.1 \neq 3$$

- **综上所述，程序员使用二进制浮点数编程时一定要非常小心，要充分考虑浮点数运算可能带来的计算误差，尽量避免对浮点数进行直接比较，在一些对误差极其敏感的情况下，建议采用十进制浮点数进行运算。**

误差来源

- 尾数位数有限，无法精确表示所有二进制小数
- 舍入方式不同，结果可能不同
- 大数吃小数：对阶时小阶尾数右移，低位丢失

易错

- 浮点数相等比较不能直接用 `==`
- 舍入误差会累积
- 不是所有十进制小数都能用有限二进制表示（如 0.1）

五、IEEE754关于数据格式的标准

IEEE 754 数据格式规范

标准	C语言数据类型	位宽	基数	阶码位数	阶码偏移常数	尾数位数	最大值量级
半精度	_Float16	16	2	5	15	10	10^5
单精度	float	32	2	8	127	23	10^{38}
扩展单精度		≥ 43	2	≥ 11		≥ 31	
双精度	double	64	2	11	1023	52	10^{308}
扩展双精度	浮点运算器内部	≥ 79	2	≥ 15		≥ 63	
四精度	long double	128	2	15	16383	112	10^{4932}
八精度	暂未支持	256	2	19	262143	236	10^{78913}
Decimal32	_Decimal32	32	10	6	101	20	10^{96}
Decimal64	_Decimal64	64	10	8	398	50	10^{384}
Decimal128	_Decimal128	128	10	12	6176	110	10^{6144}

注：带有背景色的浮点数格式为 IEEE 754 – 2008 新增标准。

知识关联：浮点表示（2.8 浮点数的表示形式以及表示范围）；规格化（2.9 浮点数的规格化）；偏移量解释（2.10A 浮点数移码偏移量的规定：IEEE754标准）；浮点加减（3.18 浮点运算——加减法）