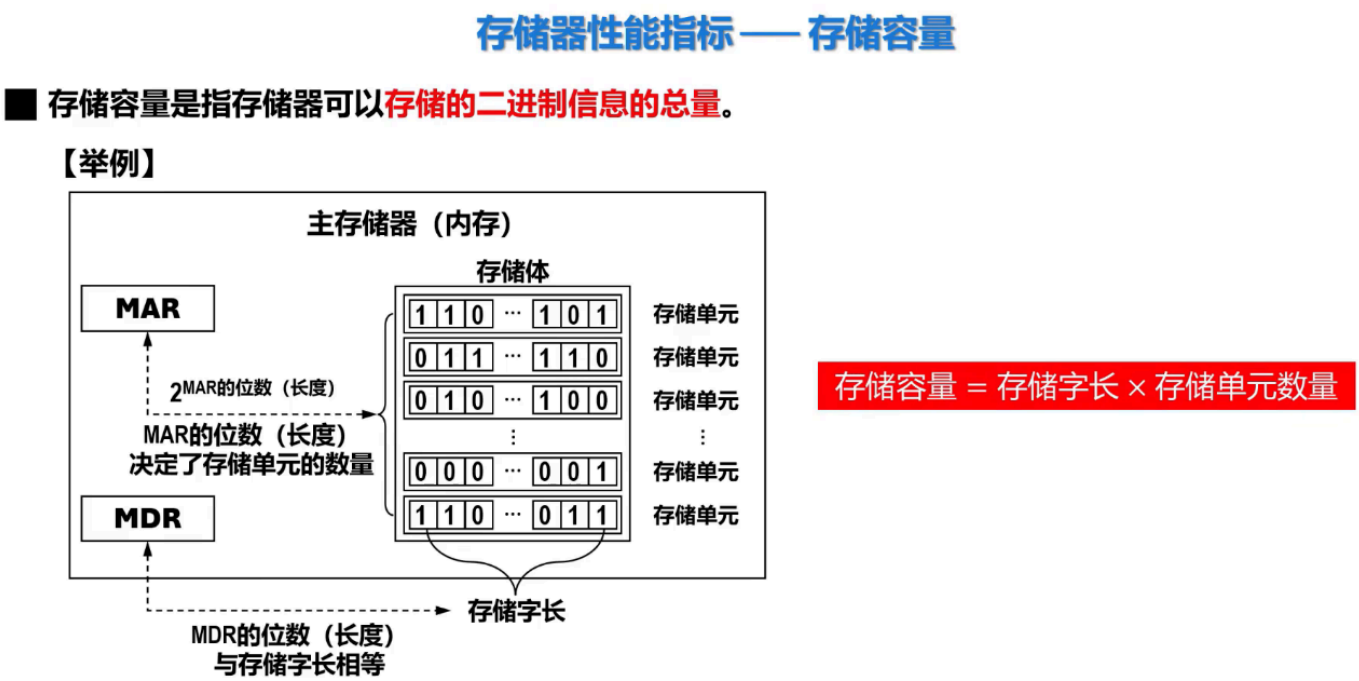
4.3 存储器的性能指标和存储系统层次结构

考纲定位：计算机组成原理 · 第 4 章 存储器（4.3）｜重要度 ★★★★★｜常见考法：选择题/大题（容量、存取时间、存取周期、带宽、层次结构）

一句话核心：容量看“字长 × 单元数”，速度看“存取时间/存取周期”，吞吐看“数据宽度 ÷ 存取周期”

一、性能指标

1.1 存储容量



公式

$$存储容量 = 存储字长 \times 存储单元数$$

- 存储字长：一个存储单元存放的二进制位数
- 存储单元数：由 MAR 的位数决定，2^n 个单元
- 容量单位：$1B = 8bit$，$1KB = 2^{10}B$，$1MB = 2^{20}B$，$1GB = 2^{30}B$

易错

- 容量单位是字节（B）还是位（b），题目经常在这里设陷阱
- 存储字长 ≠ 机器字长；存储字长是一个存储单元的位数
- MAR 位数决定“有多少个单元”，MDR 位数等于存储字长

1.2 存取速度

存储器性能指标——存取速度

存取时间

- 启动一次存储器操作到该操作完成所经历的时间。
  - 读出时间
  - 写入时间

  } 可能不同

  例如闪存读快写慢

存取周期

- 连续两次访问存储器操作（读操作或写操作）之间所需要的最短时间间隔。
- 对于主存，存取周期除包括存取时间外，还包括存储器状态的稳定恢复时间，因此存取周期略大于存取时间。



存储器带宽

- 单位时间内存储器所能传输的信息量（单位：b/s或B/s）。
- 它是衡量数据传输速率的重要指标，与一次传输的数据位的多少和存取时间的长短有关。
  - 一般而言，数据位宽越大、存取时间越短，则存储器带宽越高。

指标	定义	关键点
存取时间 T_a	一次读/写操作所需时间	从启动到完成
存取周期 T_m	连续两次访问所需的最小间隔	$T_m \geq T_a$，含恢复时间
存储器带宽 B_m	单位时间传输的信息量	$B_m =$ 数据宽度$/T_m$

公式

$$B_m = \frac{\text{数据宽度}}{T_m}$$

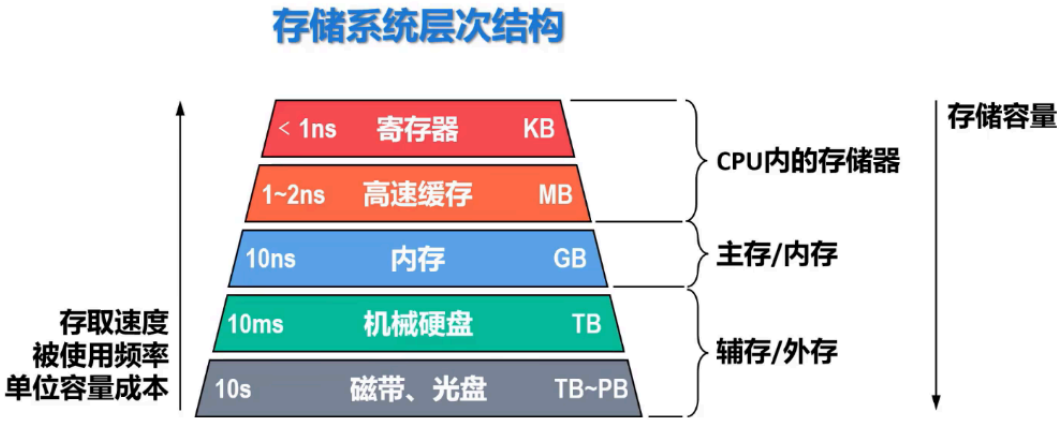
例：存取周期 $T_m = 50ns$，数据宽度 32 位，则

$$B_m = \frac{32bit}{50ns} = 640Mbit/s = 80MB/s$$

易错

- 存取时间与存取周期不是一回事；DRAM 读后需要恢复时间，$T_m > T_a$
- 带宽的单位是 bit/s 或 B/s，注意 bit 与 Byte 的换算
- 数据宽度不是地址线位数；数据线位数决定一次能传多少位

二、存储系统层次结构



■ **上层存储器可为下层存储器做缓冲，将最经常使用的数据的副本调度到上层，使得CPU只需要访问上层的快速小容量存储器即可获得大部分数据。可以有效提高存储系统的访问速度，缓解CPU与主存（内存）、主存（内存）与辅存（外存）的性能差异。**

■ **另外，使用大容量辅存（外存），缓解了主存（内存）容量不足的问题。**

基于这种层次结构，就可构建出满足应用需求的 *存储容量大、存取速度快、成本低* 的存储系统。

提炼

- 层次结构：CPU 寄存器 → Cache → 主存 → 辅存
- 越往上：速度越快、容量越小、单位成本越高
- 越往下：速度越慢、容量越大、单位成本越低
- 上层作为下层的缓存，靠程序局部性提高整体性能

两个经典层次

- Cache—主存层次：解决 CPU 与主存速度差距，由硬件自动管理
- 主存—辅存层次：解决主存容量不足，由 OS 与硬件共同管理，即虚拟存储器

易错

- Cache—主存层次对程序员透明；主存—辅存层次对程序员可见（地址空间变大）
- 层次结构不是“把数据全部复制到上层”，而是按块调入、按需替换
- 存储器的“带宽”与总线的“带宽”计算方式类似，但对象不同

知识关联：存储层次（4.1 存储器概述）；Cache 命中率（4.21 Cache——基本概念）；虚拟存储器（4.31 虚拟存储器——概念和工作原理）；总线带宽（7.3 总线的概述——性能指标）